GitHub 仓库：https://github.com/Xuxalk/ECNU-AI-LAB3

CIFAR-10 图像分类 模型设计与优化实验

从轻量级 CNN 到 ResNet20 + SE + CutMix

课程：当代人工智能实验课 作业三　　姓名：许嘉宏 学号：10245501457

实验平台：Apple M4 / MPS　　报告日期：2026 年 11 月

摘要

针对 CIFAR-10 十类图像分类，项目从轻量级 CNN 基线出发，比较常规增强与 Cutout，随后引入残差结构、SE 通道注意力、余弦退火和 CutMix。最终 ResNet20 + SE + CutMix 在固定测试集上达到 89.20% 准确率和 89.17% Macro F1，较 CNN Crop + Flip（seed 123）提高 3.25 个百分点。猫、狗召回率分别为 76.10% 和 82.40%。该结果是多阶段实验的累计表现；由于最终方案仅运行一个随机种子，不能据此断言提升具有稳定性。

1 研究目标与数据集

目标是建立可复现的图像分类流程，并通过受控记录比较模型结构和训练策略。CIFAR-10 含 60,000 张 32×32 RGB 图像，覆盖 airplane、automobile、bird、cat、deer、dog、frog、horse、ship、truck 十类。官方训练集用于训练和验证，官方测试集用于最终评估。

子集	样本数	每类	用途
训练	45,000	4,500	参数学习；随机增强仅作用于训练数据
验证	5,000	500	选择验证准确率最高的 checkpoint
测试	10,000	1,000	训练和选模完成后的最终评估

训练/验证索引由 seed 42 分层生成，全部实验复用；训练 seed 123 控制模型初始化和随机训练过程。预处理使用 ToTensor 与 RGB 标准化，均值 (0.49135, 0.48207, 0.44655)，标准差 (0.24713, 0.24362, 0.26172)。Crop + Flip 为 RandomCrop(32, padding=4) 与 RandomHorizontalFlip(p=0.5)。

当前运行环境：Python 3.14.10、PyTorch 2.15.0、TorchVision 0.29.2；设备为 Apple M4 MPS。

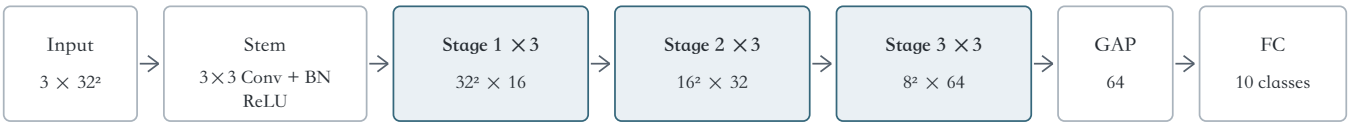
2 模型结构与训练方法

2.1 网络结构

模型	结构与作用	参数量
原始 CNN	3 个卷积块，通道 32/64/128；每块两层 3×3 Conv、BatchNorm、ReLU 与 MaxPool；GAP、Dropout(0.3)、10 类分类头。	288,746
ResNet20 + SE	CIFAR 风格 stem 与 3 个 stage（16/32/64 通道，各 3 个 BasicBlock）；残差 shortcut；每个 BasicBlock 含 SE（reduction=16）；GAP 与 10 类分类头。	274,847

残差分支保留输入信息；SE 对全局池化后的通道响应进行压缩和门控。下图先概览整网的特征尺寸变化，再展开单个带 SE 的残差块。项目未包含去掉 SE 的同结构对照，因此不能单独估计 SE 的贡献。

(a) ResNet20 + SE 总体结构



(b) BasicBlock 与 SE 通道注意力

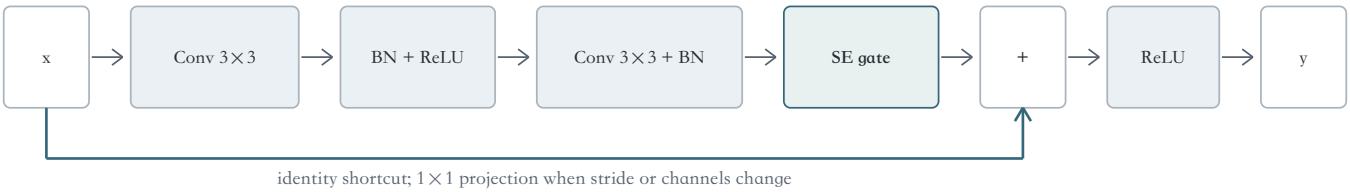


图 1 (a) CIFAR 风格 ResNet20 + SE。Stem 后接三个各含 3 个 BasicBlock 的 stage；Stage 2/3 首块完成下采样。(b) 主分支经 SE 门控后与 shortcut 相加。SE 将全局池化向量经 FC(C/16)、ReLU、FC(C)、Sigmoid 转为通道权重。

2.2 训练配置

项目	CNN 增强与 ResNet 30 Epoch	ResNet + SE 100 Epoch
优化器 / 损失	AdamW / CrossEntropyLoss	AdamW / CrossEntropyLoss
学习率 / 权重衰减	0.001 / 0.0001	0.001 / 0.0001
Batch / Epoch / Seed	128 / 30 / 123（增强消融含多 seed）	128 / 100 / 123
调度 / 增强	固定 LR；Crop + Flip；部分组加 ColorJitter 或 Cutout	CosineAnnealingLR，T_max=100，eta_min=1e-5；Crop + Flip
CutMix 扩展	不使用	alpha=1.0，应用概率 0.5；只在训练 batch 中使用

2.3 CutMix 与训练流程

训练 batch 以 0.5 概率从 Beta(1,1) 采样 lambda，替换另一张图像的随机矩形区域，并按实际面积重算 lambda' = 1 - ((x2-x1)(y2-y1))/(W*H)。损失为 lambda' CE(f(x_mix), ya) + (1-lambda') CE(f(x_mix), yb)；未触发时使用普通交叉熵。验证和测试阶段不使用 CutMix。

每个 Epoch 记录训练/验证损失、准确率、实际学习率和耗时。best checkpoint 按验证准确率选取；last checkpoint 保存模型、优化器、调度器及随机状态。所有 ResNet 阶段从随机初始化开始，CosineAnnealingLR 每轮结束后 step。

3 实验结果与训练过程

所有模型共享固定数据划分与测试集。CNN 增强组中 Crop + Flip 与 Cutout 各运行 3 个种子；ColorJitter、ResNet20 与 CutMix 的相应结果为单次运行。

模型	参数量	测试准确率	Macro F1	猫召回	狗召回	最佳验证	耗时
CNN + Crop/Flip seed 123	288,746	85.95%	85.94%	67.40%	84.90%	86.76% / 25	9.98 分
ResNet20 + SE 30 Epoch	274,847	86.26%	86.20%	66.40%	83.50%	86.84% / 30	18.91 分
ResNet20 + SE Cosine 100	274,847	88.49%	88.48%	77.00%	82.50%	89.74% / 95	65.78 分
ResNet20 + SE CutMix 100	274,847	89.20%	89.17%	76.10%	82.40%	90.48% / 82	64.34 分

最终模型较原 CNN Crop + Flip 提高 3.25 个百分点；与相同 100 Epoch Cosine 配置相比，CutMix 单次测试准确率提高 0.71 个百分点、Macro F1 提高约 0.69 个百分点。参数量较 CNN 少约 4.8%，训练耗时与 Cosine 基线接近。

增强策略比较：原始 CNN

方案	测试准确率	猫召回	狗召回	运行次数
无增强	82.27%	57.90%	76.20%	1
Crop + Flip	85.86% ± 0.21	66.23% ± 1.02	81.73% ± 2.74	3
+ ColorJitter	85.67%	72.90%	74.50%	1
+ Cutout	85.59% ± 0.53	73.50% ± 8.49	76.13% ± 4.55	3

多种子均值表明 Crop + Flip 的总体准确率略高且运行间波动较小；Cutout 的猫召回较高、狗召回较低，体现类别取舍。ColorJitter 只有一个种子，无法判断稳定影响。

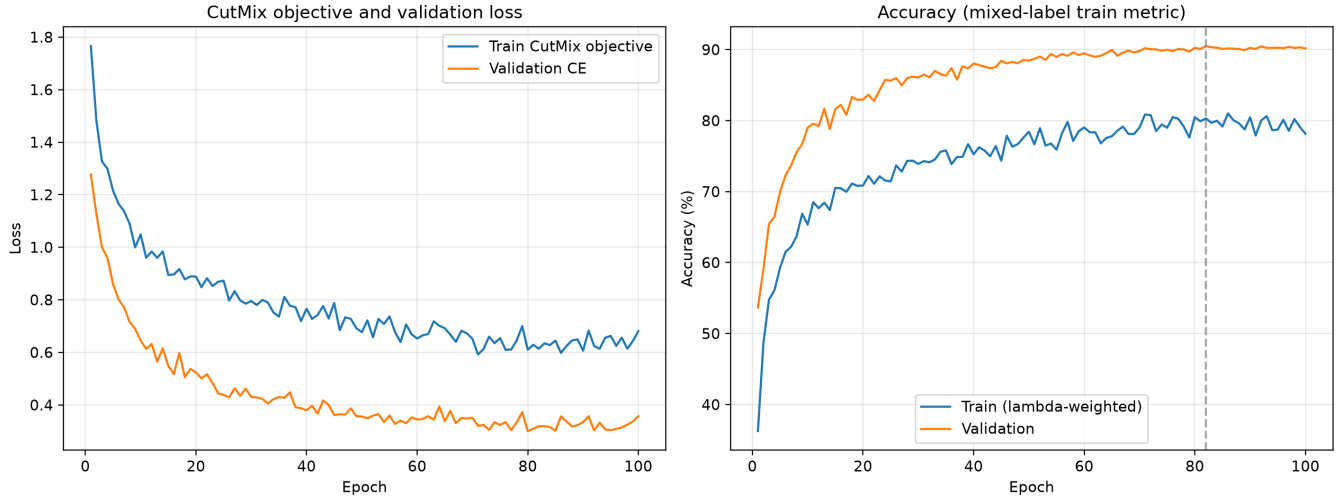


图 2 CutMix 100 Epoch 训练与验证曲线。第 82 轮验证准确率达到 90.48%，第 100 轮为 90.16%；验证损失从第 80 轮最低值 0.3005 回升至第 100 轮的 0.3571。训练准确率为 CutMix 双标签 lambda 加权口径，不能与验证准确率直接作差判断过拟合。

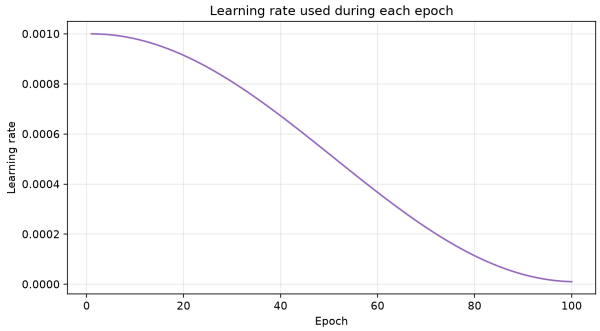


图 3 CosineAnnealingLR，T_max=100，eta_min=1e-5。

Cosine 100 Epoch 的最佳验证准确率为 89.74%（Epoch 95），测试准确率为 88.49%。训练准确率最终达 98.13%，验证准确率最终为 89.58%；验证损失在 Epoch 51 最低为 0.3946，末轮升至 0.4643，显示后期验证退化。该阶段相较 30 Epoch 同时增加训练轮数并改变调度器，不能单独估计 Cosine 的贡献。

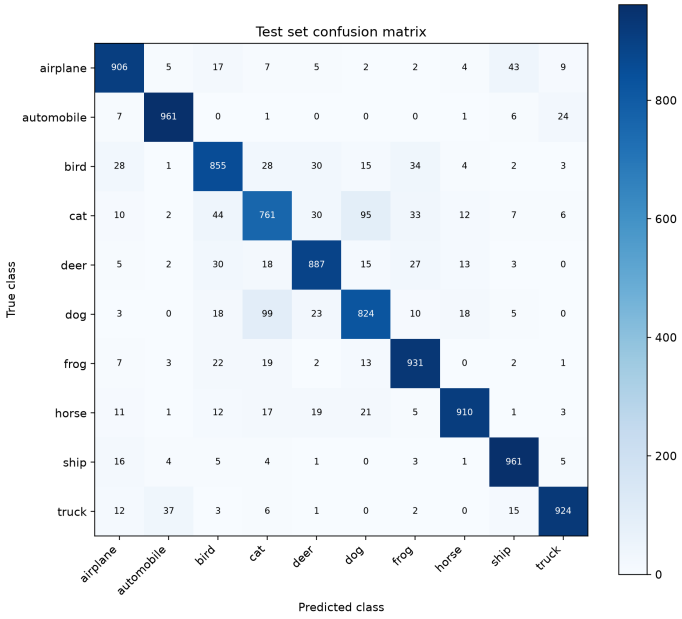
4 类别表现与误分类分析

按验证准确率选择 Epoch 82 的 best checkpoint 后，在 10,000 张测试图像上评估：准确率 89.20%，Macro Precision 89.17%，Macro Recall 89.20%，Macro F1 89.17%。测试集每类均为 1,000 张，因此 accuracy 与 macro recall 相同。

逐类别 Precision、Recall 与 F1

类别	Precision	Recall	F1
airplane	90.15%	90.60%	90.37%
automobile	94.59%	96.10%	95.34%
bird	84.99%	85.50%	85.24%
cat	79.27%	76.10%	77.65%
deer	88.88%	88.70%	88.79%
dog	83.65%	82.40%	83.02%
frog	88.92%	93.10%	90.96%
horse	94.50%	91.00%	92.72%
ship	91.96%	96.10%	93.99%
truck	94.77%	92.40%	93.57%

图 4 测试集混淆矩阵



混淆矩阵显示主要错误集中在猫狗互混：95 张猫被判为狗，99 张狗被判为猫；猫另有 44 张被判为 bird。airplane→ship 43 张、truck→automobile 37 张。总体准确率掩盖了猫类召回率较低这一弱项。

误分类样本与可解释性

Grad-CAM 示例来自原始 CNN Crop + Flip（seed 42）的固定验证集，用于解释早期误分类，不代表 CutMix 最终模型的注意力。cat→dog、cat→bird 等样本中，热区有时覆盖主体，有时落在局部纹理或背景；8×8 遮挡分析也显示不同位置会改变目标类别 logit。低分辨率图像、遮挡步长和定性选例限制了解释范围，热图不能证明模型依赖某一特征的因果关系。

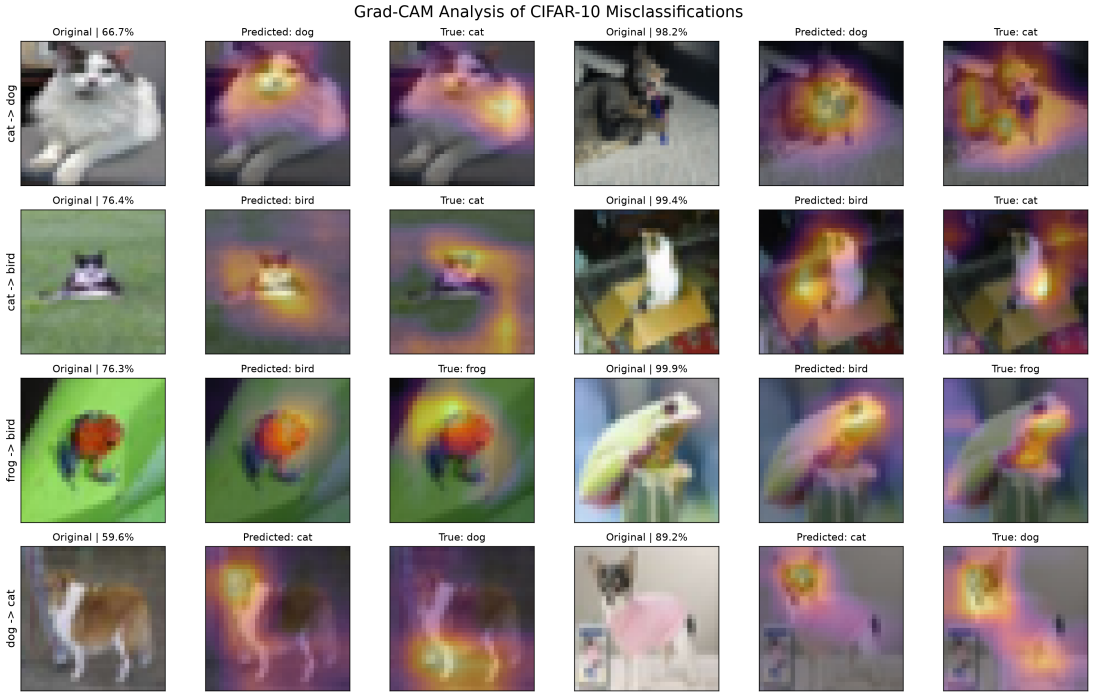


图 5 Crop + Flip CNN 验证集误分类样例及 Grad-CAM（原图、预测类响应、真实类响应）。

5 讨论、结论与复现

结果解释

从无增强 CNN 的 82.27% 到最终 89.20%，累计提升 6.93 个百分点；相对 CNN Crop + Flip seed 123 提升 3.25 个百分点。该累计差异经历了结构、训练轮数、学习率调度和增强方法变化，不能解释为某一模块的独立贡献。30 Epoch ResNet20 + SE 的准确率为 86.26%；100 Epoch Cosine 达到 88.49%，CutMix 达到 89.20%。30 到 100 Epoch 同时改变训练时长与调度方案，不能单独归因于余弦退火。

CutMix 相对 Cosine 基线提高整体准确率和 Macro F1，但猫召回率下降 0.90 个百分点，狗召回率下降 0.10 个百分点。CutMix 与 Cosine 的训练耗时分别为 64.34 和 65.78 分钟，单次运行不足以说明速度差异。最终验证准确率从峰值回落 0.32 个百分点，验证损失末段上升，存在轻微验证退化。

结论

在当前固定配置和单次随机种子下，ResNet20 + SE + CutMix 是项目中表现最好的已报告模型；它以 274,847 个参数达到 89.20% 测试准确率，整体性能提升伴随猫狗类别召回未同步改善。训练阶段至此收尾，后续结论应由受控复验而非无对照延长训练来检验。

局限与后续验证

ResNet 与 CutMix 各只有一个种子，无法估计方差；缺少不含 SE 的同结构对照；项目多轮实验使用同一测试集，跨轮查看结果可能产生研究层面的选择偏差。Grad-CAM 与遮挡结果仅作定性观察。当前结果是项目中已报告的最佳单次结果，不等同于独立盲测下的无偏性能保证。若继续研究，应优先做多 seed 复验、ResNet20 去 SE 对照和固定学习率 100 Epoch 对照。

复现入口

从仓库根目录运行；依赖、数据准备、训练与评估说明见 README.md。测试集只在训练和验证选模后用于最终评估。数据与权重按项目设置由 Git 忽略；运行评估需本地存在相应 checkpoint。

```
conda activate cifar10
python -m src.train --config configs/resnet20_se_cutmix_100_seed123.json
python -m scripts.evaluate_experiment --run resnet20_se_cutmix_100_seed123
```

核心实现：src/train.py（共享训练循环与 checkpoint）、models/resnet20_se.py（网络）、src/cutmix.py（CutMix）、scripts/evaluate_experiment.py（测试指标与图表）。最终 history、配置、逐类指标及混淆矩阵保存在 experiments/resnet20_se_cutmix_100_seed123/。

参考文献

[1] Krizhevsky A. Learning Multiple Layers of Features from Tiny Images. 2009. [2] He K, Zhang X, Ren S, Sun J. Deep Residual Learning for Image Recognition. CVPR, 2016.
[3] Hu J, Shen L, Sun G. Squeeze-and-Excitation Networks. CVPR, 2018. [4] DeVries T, Taylor G W. Improved Regularization of CNNs with Cutout. arXiv:1708.04552, 2017.
[5] Yun S, et al. CutMix: Regularization Strategy to Train Strong Classifiers With Localizable Features. ICCV, 2019. [6] Selvaraju R R, et al. Grad-CAM. ICCV, 2017.